Comment se servir des TEI Guidelines?

janvier 2015



Les Cinq Etapes du chemin de l'Eveil TEI

- Modelisation : quels sont les buts et les objets de votre projet ?
- Orientation : est-ce que vos objets sont déjà reconnus par la TEI ?
- Oeclaration : comment créer une specification TEI-conforme ?
- Documentation: comment documenter vos pratiques TEI?
- Validation : comment valider vos efforts ?



Modelisation

La modelisation de vos données est une préalable essentiel. Que vous vous servez de UML, de RDBMS, de SKOS, ou quoique ça soit d'autre, si vous n'avez pas un modèle explicite des choses que vous espérez gérer, vous aurez de grands difficultés.





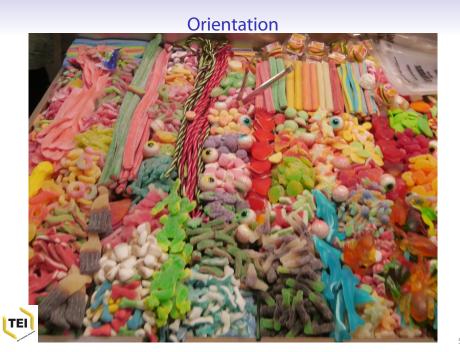
Analyse des données classique

On identifie...

- les "objets d'interêt"
- leurs attributs et propriétés
- les relations entre objets
- les procédures/traitements essentiels envisagés

Ce travail est essentiel pour n'importe quel projet d'informatisation





Comment s'orienter?

Les TEI Guidelines, imprimées ou en ligne, se divisent en deux gros parties :

- une séquence de 23 chapitres, dont la plupart correspondent à un module
- des listes alphabétiques de définitions exhaustives de classes (183), d'éléments (546), d'attributs (470), de macros(8), et vde types de données (28).

Comment savoir quel élément (etc) choisir pour tel ou tel entité identifiée dans votre analyse préalable ? Comment savoir que vous avez besoin d'une 'licorne'?



La triste vérité...

- Désolé, mais il n'y a aucune méthode scientifique ; aucun raccourci pour cela...
- Il faut étudier les exemplaires et les définitions pour savoir si cet élément TEI si prometteur s'applique en effet à votre cas
- comme c'est le cas pour d'autres types de mapping...

Pour chacun(e) des entités/concepts identifiés dans votre modèle, il faut décider :

- quel objet TEI lui correspond parfaitement? (s'il existe)
- quel objet TEI lui ressemble et quelles petites modifications seraient nécessaires pour qu'il lui corresponde?
- quelle lacune TEI votre analyse vous permettra de corriger (oui, elles existent les licornes!)



Par exemple...





Structuration

- C'est un livret de la bibliothèque bleue -- un 'chapbook'-organisé de manière traditionelle, avec des piéces liminaires (page à titre, une table des matières) et plusieurs chapitres
- chacun des chapitres contient :
 - un titre et une sommaire
 - des paragraphes narratives
 - des passages de dialogue
 - des noms de lieux, noms de lieux, noms d'évènement etc.
- chaque page est dôtée de matières paratextuelles (signatures, etc.)
- Et plusieurs images



Structure(s) d'un document TEI-XML

- Chaque document TEI est représenté par un élément <TEI>, regroupant de texte et des metadonnées
- On peut également regrouper des <TEI> dans un <teiCorpus>

Le terme *document* n'a aucune définition formelle, mais d'habitude il correspond à un object complet (un livre par ex). D'autres possibilités ne sont pas exclus...



Un document TEI peut rassembler...

- un ensemble de représentations visuelles (<facsimile>)
- ou une transcription textuelle (<text>)
- ou une transcription documentaire (<sourceDoc>)
- ou ces trois types d'objet conjointement



Un TEI Corpus par contre....

Cette structure servirait par ex à une collection de livres de cette sorte



L'entête TEI

Inspiré de la pratique AACR2, il contient quatre éléments principaux

- fileDesc>: une description bibliographique de la ressource et de ses origines
- <encodingDesc>: une description du rapport entre la ressource et la source (ou les sources) dont elle dérive
- <pr
- <revisionDesc>: sommaire de l'historique des modifications de la ressource

tous facultatifs, sauf le premier



L'entête minimal

```
<teiHeader>
<fileDesc>
<titleStmt>
<title>titre de la ressource</title>
</titleStmt>
<publicationStmt>
<ppagence de distribution de la source</p>
</publicationStmt>
<sourceDesc>
<ppprovenance de la source</p>
</sourceDesc>
</fileDesc>
</teiHeader>
```



L'élément <text>

Un text peut etre simple ou complexe :

- un text simple est un objet autonome, complète en soi, par ex un roman, un poème
- un text complèxe ou composé rassemble d'autres textes, par ex une anthologie, une collection de poésies



TEI text structure (1)

Un document simple:



TEI text structure (2)

Un document composé:

```
<text>
 <front>
<!-- ... -->
</front>
<group>
  <text n="1">
   <body>
    </body>
  </text>
  <text n="2">
   <body>

   </body>
  </text>
 </group>
 <back>
<!-- ... -->
 </back>
</text>
```



Entrons dans le <body> d'un <text>...

D'habitude, on y trouve des divisions

- qui s'emboitent
- l'attribut @type sert à distinguer les divisions par fonction ou par niveau
- l'attribut @n fournit un nom ou un nombre pour une division déjà numérotée d'une manière quelconque
- l'attribut @xml:id fournit une identifiant unique
- l'attribut @xml:lang identifie la langue (humaine) du contentu de la division

Ces deux derniers sont deux des attributs dits *globaux* qui peuvent s'attacher à n'importe quel élément TEI



Composants des divisions

Vous avez déjà rencontré ...

- éléments liminaux spécialisés : <head>, <trailer>, etc.
- en prose : les , <list> etc.
- en poésie : les <lg>, <l> ...
- en drame : les <sp>, <stage> etc.
- partout : les <note>, les <bibl>, les <figure> ...



Composants des composants des divisions

Vous avez déjà rencontré ...

- éléments de repérage : les <lb>, <pb> etc.
- éléments et attributs de mise-en-forme : <hi>, @rend,
 @rendition etc.
- éléments sémantiques : <date>, <name>, <placeName> etc.
- éléments para-textuels : <sic>, <corr>, <add> etc.
- etc etc etc



Par exemple ...

```
<text>
 <front>
   <titlePage> </titlePage>
   <div type="prolog" xml:id="P1">
     <head>Ici commence le proloque de
lecteur</head>
<!-- ... -->
     <trailer>Ici fine le proloque</trailer>
   </div>
 </front>
 <body>
   <div type="chap" xml:id="C1">
     <head>Comment le conte Roalt avoit une
belle fille nomee Felisse sur montant en
            beautee toutes autres dames et
damoiselles et envoya querir Guyonet filz de
son
            seneschal pour demeurer en sa
court.</head>
<!-- ... -->
   </div>
 </body>
 <back>
<!-- ... -->
 </back>
</text>
```





Composants des divisions

Qu'est-ce qu'on trouve dans une division?

- Un ou plusieurs titres (au debut et/ou à la fin), balisés avec
 chead> ou <trailer>
- de la prose, divisée en paragraphes () ou listes (<list>)
 contenant des <item> et facuiltativement des <|abel>
- de la poésie, divisée en vers (<l>), facultativement regroupés en strophes (<lg>)
- de la théatre, divisée en énoncés (<sp>), contenant une mélange de ou de <l> facultativement entrecoupée de didascalies (<stage>)

... et bien sûr des sous-divisions



Exemple prosaique ...

```
<div n="1">
  <head>La Fête</head>
  C'était à Mégara, faubourg de Carthage, dans les jardins
d'Hamilcar.
  Les soldats qu'il avait commandés en Sicile se donnaient
un grand festin pour
    célébrer le jour anniversaire de la bataille d'Eryx, et
comme le maître était absent
    et qu'ils se trouvaient nombreux, ils mangeaient et ils
buvaient en pleine
    liberté.
<!-- ... ->
</div>
```



Exemple poétique

```
<div type="sonnet">
 <la type="duatrain">
   <l>Les amoureux fervents et les savants austères</l>
   <l>>Aiment également, dans leur mûre saison,</l>
   <l>Les chats puissants et doux. orqueil de la maison.</l>
   <l>Oui comme eux sont frileux et comme eux sédentaires.</l>
 </lq>
 <la type="duatrain">
   Amis de la science et de la volupté</l>
   <l>>Ils cherchent le silence et l'horreur des ténèbres ;</l>
   <l>L'Erèbe les eût pris pour ses coursiers funèbres.</l></l>
   <l>>S'ils pouvaient au servage incliner leur fierté.</l>
 </lq>
 <la type="tercet">
   Ils prennent en songeant les nobles attitudes</l>
   <l>Des grands sphinx allongés au fond des solitudes,</l>
   <l>Qui semblent s'endormir dans un rêve sans fin ;</l></l>
 </la>
 <ld>type="tercet">
   Leurs reins féconds sont pleins d'étincelles magigues,</l>
   <l>Et des parcelles d'or, ainsi qu'un sable fin.
   Etoilent vaguement leurs prunelles mystiques.</l>
 </la>
</div>
```



Exemples dramatiques (1)

```
<sp who="#V">
 <speaker>Vladimir</speaker>
 Relève ton pantalon.
</sp>
<sp who="#E">
 <speaker>Estragon</speaker>
 Que j'enlève mon pantalon ?
</sp>
<sp who="#V">
 <speaker>Vladimir</speaker>
  <emph>RE</emph>lève ton pantalon.
</sp>
<sp who="#E">
 <speaker>Estragon</speaker>
 C'est vrai. 
 <stage>Il relève son pantalon. Silence.</stage>
</sp>
<sp who="#V">
 <speaker>Vladimir</speaker>
 Alors, on v va ?
</sp>
<sp who="#E">
 <speaker>Estragon</speaker>
 Allons-v.
</sp>
<stage>Ils ne bougent pas.</stage>
tvpe="speakers">
 <item xml:id="V">Vladimir</item>
 <item xml:id="E">Estragon</item>
 list>
```

Exemples dramatiques (2)

```
<sp>>
 <speaker>Alceste.
 Non : i' ai résolu de n' en pas faire un pas.</l>
 quart="I">J' ai tort, ou j' ai raison.</l>
</sp>
<sp>
 <speaker>Philinte.</speaker>
 | part="F">Ne vous y fiez pas.</l>
</sp>
<sp>>
 <speaker>Alceste.</speaker>
 | part="I">Je ne remuerai point.</l>
</sp>
<sp>
 <speaker>Philinte.
 <l part="F">Votre partie est forte,</l>
 <l part="I">et peut, par sa cabale, entraîner...</l>
</sp>
<sp>
 <speaker>Alceste.
 part="F">Il n' importe.</l>
</sp>
<sp>>
 <speaker>Philinte.</speaker>
 | part="I">Vous vous tromperez.</l>
</sp>
<sp>
 <speaker>Alceste.
 Soit. J' en veux voir le suite.</l>
 sp>
```

Composants textuels typiques

- des séquences de mots qui sont (par convention) mises en evidence, par exemple pour leur donner une emphase, parce qu'ils sont en langue étranger, ou cités etc,
- des mots qui pourraient être d'interêt non-lexicale "data-like" (des noms de lieu ou de personne, des dates, des chiffres ...)
- des indications d'interventions éditorielles (corrections, normalisations, ajouts, ratures...)
- des références et des liens
- listes, notes, annotations, graphies, tables, citations bibliographiques...
- indications de structuration dans une autre hiérarchie, par exemple frontières de pages

TEI fournit des balises pour toutes ces choses : mais il faut faire une choix, selon les objectifs de son projet



La mise en evidence et son interprétation

On voit une partie en italique ou en petites capitales : et on se demande pourquoi... par exemple :

Mais qu'est-ce que cette politesse? Comment être poli? Et avec qui? Il nous le dit dans Histoires. Un marchand de pierres à briquet « élève la voix le soir dans les couloirs de la station Javel ». Le poème ajoute : « Et ses grands écarts de langage Déplaisent à la plupart des gens ». Bien sûr, mais Prévert pense que la parole convainc, et il continue « mais la brûlure de son regard Les rappelle à de bons sentiments », plus prompts à l'accord que les gens du Dîner de Têtes, « ceux qui mettent un loup sur leur visage quand ils mangent du mouton », les « cartonnés officiels », mais le Dîner de Têtes est un des premiers écrits de Prévert.



La mise en evidence, et son interprétation - 1

Plusieurs politiques sont envisageables :

 on signale la présence d'une mise en évidence sans distinction particulière avec <hi> (highlighted : distinction typographique)

```
... mais Prévert pense que la <hi>parole</hi> convainc, et il continue «
<hi>mais
    la brûlure de son regard Les rappelle à de bons sentiments</hi> », plus
prompts
à l'accord que les gens du <hi>Dîner de Têtes</hi>, ....
```

 on essaie de distinguer l' objectif sémantique de ces mises en evidence : en ce cas, il y a un <emph> (emphase linguistique), un <quote> (citation) et un <title> (titre):

```
... mais Prévert pense que la <emph>parole</emph> convainc, et il continue «
<quote>mais la brûlure de son regard Les rappelle à de bons sentiments</quote>
», plus prompts à l'accord que les gens du <title>Dîner de Têtes</title>,
....
```



La mise en evidence et son interprétation - 2

• on peut combiner ces deux niveaux de description ...

```
... mais Prévert pense que la <emph rend="italic">parole</emph> convainc, et il continue « <q rend="italic">mais la brûlure de son regard Les rappelle à de bons sentiments</q> », plus prompts à l'accord que les gens du <title rend="italic">Dîner de Têtes</title>, ....
```

- Les valeurs possibles de l'attribut @rend sont à définir pour chaque projet.
- Des attributs complémentaires @style ou @rendition permettent l'usage des systèmes déjà standardisés, notamment le CSS.



Phrases en langues étrangères

- L'attribut @xml:lang peut s'attacher à tout élément TEI
- L'élément <foreign> est disponible s'il n'y a pas d'autre sémantique à signaler
- La langue est identifiée par son code normalisé ISO

```
As-tu lu <title xml:lang="de">Die
Dreigroschenoper </title>?
```

```
Tout d'un coup il exclame <foreign xml:lang="de"> himmel! </foreign>
```



Noms de lieux et de personnes

La balise <rs> (referring string) est très générique :

Les balises <name>, <persName>, ou <persName> sont plus spécifique :

```
Le premier dîner que
<persName ref="http://fr.wikipedia.org/wiki/Marquis_de_Norpois">M. de
   Norpois</persName> fit à la maison, une année où je jouais encore aux
<placeName>Champs-Élysées</placeName>, est resté dans ma mémoire, parce que
l'après-midi de ce même jour fut celui où j'allai enfin entendre <name>la
   Berma</name>, en « matinée », dans <title>Phèdre</title>...
```

Nous allons traîter ce sujet en plus de détail la semaine prochaine.



Les références croisées et les liens

Pour relier deux endroits d'un ou plusieurs textes, on utilise l'un des éléments <ptr> ou <ref>.

```
Voir <ref target="#pv1894_61"> procès-verbal no 61</ref>.
```

```
Voir <ptr target="#pv1894_61"/>.
```

L'attribut @target spécifie l'objet ciblé par la référence, que ce soit en fournissant l'identifiant d'un autre élément dans le même document, ou en fournissant une adresse complète sur le Web (un URL)

```
Voir <ptr target="http://www.example.org/example.xml#pv1894_61"/>
```

Dans ces exemples, on pointe sur la section suivante :

```
<div xml:id="pv1894_61">
<!-- ... ->
</div>
```



lusieurs autres attributs de type "pointeur" sont disponibles, purnissant une gamme de type de liens plus spécialisés.

Expressions temporelles

Les dates qui figurent dans les textes manifestent beaucoup de variation lexicalle, pour ne rien dire des variations des systèmes de calendrier. Pour comparer et contrôler de telles expressions d'une manière efficace, il faut les normaliser. La TEI propose un élément <date> pour identifier ces expressions, et plusieurs attributs pour leur normalisation.

```
<date when="1980-02-21">21 février
1980</date>
<date when="1990-02-21" xml:lang="en">21 September,
1990</date>
```

```
<date when="2001-09-11T12:48:00">11
septembre, neuf heures moins douze, EST</date>
```

```
Décret de la Convention <date when="1794-10-30">9 Brumaire An III</date>
```



Les images

- <graphic> précise la location d'une image, illustration, etc. faisant partie du texte)
- <figure> précise une partie iconographique plus complexe, rassemblant par exemple plusieurs images, un titre, des <figDesc> pour les decrire
- L'attribut @facs fournit un lien externe sur une représentation supplémentaire de la source encodée
- L'attribut @url par contre (sur <graphic>) fournit un lien sur une image qui est intégrale à cette source



Par exemple





Bibliographies

```
<bibl xml:id="MK_73">Sturm, U. & Drang, F. :
<title>Musikalische Katastrophe</title>.
(Berlin, W. de Gruyter, 1973)</bibl>
```

- Une référence bibliographique peut être plus ou moins structurée, en se servant d'éléments tels que <author>,</editor>, <title>, <pubPlace>, <publisher>, <series> etc.
- les conventions de présentation des références ne sont pas forcément à encoder

```
<br/>
<bibl xml:id="MK73">
    <author>Sturm, U.</author>
    <author>Drang, F.</author>
    <title xml:lang="de" level="m">Musikalische Katastrophe</title>
    </title>
    <pubPlace>Berlin</pubPlace>
    <publisher>W. de Gruyter</publisher>
    <date>1973</date>
    /bibl>
```

Et pour terminer, les notes

```
3
     l'écris : j'habite ma feuille de papier, je l'investis, je
la parcours.
     Je suscite des blancs, des espaces (sauts dans le sens :
discontinuités, passages, transitions).
                                                                  l'écris
                                                                  dans la
 à la ligne. Je renvoie à une note en bas de page
                                         le change de feuille.
      1. l'aime beaucoup les renvois en bas de page, même si je
  n'ai rien de particulier à y préciser.
                                                             19
```

```
<div n="3">
 J'écris : j'habite ma feuille de
papier, je l'investis, je la
parcours.
 Je suscite des <hi>blancs</hi>. des
<hi>espaces</hi> (sauts dans le sens :
   discontinuités, passages,
transitions).
<note place="margin">J'écris dans la
      marge...</note>
 Je vais <lb/>à la
ligne. Je renvoie à une note en bas de
page<note place="foot">J'aime beaucoup
les renvois en bas de page, même si je
n'ai rien de
      particulier à y préciser.</note>
 Je change de
feuille.
</div>
<pb n="20"/>
```



Vous vous sentez un peu accablé?

Tout ceci n'est qu'une des manières de se servir de la TEI.

- TEI est un système modulaire. On s'en sert pour créer un système d'encodage selon ses propres besoins, en sélectionnant des modules spécifiés par la TEI
- Chaque module définit un groupe d'éléments (et leurs attributs)
- on peut sélectionner les éléments voulus, et même en changer des propriétés
- on peut y mélanger des éléments nouveaux, ou bien natifs ou bien d'autres standards

Il faut définir ses objets avant de se servir la TEI!



La TEI facilite un balisage 'intelligent'

La TEI s'applique à l'encodage des...

- composants structuraux et fonctionnels d'un texte
- transcriptions diplomatiques des sources historiques, des images, des annotations
- liens, correspondances, alignements
- données et entités : par exemple de temps, personnes, lieux ou événements
- annotations peritextuelles et métatextuelles (correction, suppression, ajouts)
- analyses linguistiques
- métadonnées de plusieurs types
- ... et définitions formelles de schéma XML!

On est vraiment gâté de choix



Liste des modules TEI

analysis	Simple analytic mechanisms		
certainty	Certainty and uncertainty		
core	éléments common to all TEI documents		
corpus	Header extensions for corpus texts		
declarefs	Feature system déclarations		
dictionaries	Printed dictionaries		
drama	Performance texts		
figures	Tables, formulae, and figures		
gaiji	Character and glyph documentation		
header	The TEI Header		
iso-fs	Feature structures		
linking	Linking, segmentation and alignment		
msdescription	Manuscript Description		
namesdates	Names and dates		
nets	Graphs, networks and trees		
spoken	Transcribed Speech		
tagdocs	Documentation of TEI modules		
tei	déclarations for datatypes, classes, and macros avail-		
	able to all TEI modules		
textcrit	Text criticism		
textstructure	Default text structure		
transcr	Transcription of primary sources		
verse	Verse structures		



Niveaux de validation

Un document TEI-XML doit:

- respecter les règles syntaxiques d'XML;
- être valide par rapport à un schéma quelconque;
- respecter la sémantique définie de chaque élément TEI utilisé

Un schéma exprime d'une manière formelle et validable par logiciel une partie importante de ces règles

Un TEI ODD nous permet de construire un schéma adéquat à nos besoins



Comment effectuer notre choix de balises?

Nous aurons besoins de plusieurs choses :

- un schéma formel (en langue informatique tel que DTD, RELAXNG, W3C Schema, Schematron) qui peut contrôler:
 - quelles balises sont disponibles?
 - dans quels contextes ?
 - avec quels attributs?
 - avec quelles valeurs?
 - en respectant quelles contraintes ?
- une documentation pour expliquer nos principes éditoriaux, nos principes de choix de balises, etc. aux utilisateurs/ developpeurs:
 - en plusieurs langues naturelles
 - en plusieurs formats bureautiques (PDF, Word, HTML, epub...)
- des outils informatiques pour transformer et gèrer nos données XML



Propositions de la TEI

Ayant elle-même ces mêmes besoins, la TEI vous propose :

ODD Un vocabulaire XML pour définir les vocabulaires XML Stylesheets Un ensemble de feuilles de style XSLT très générique pour la conversion des documents XML TEI

Roma

Un logiciel pour traiter des documents exprimés dans ce vocabulaire, pour en faire ressortir

- des schémas RELAXNG, DTD, etc.
- des manuels "mode d'emploi" en HTML, PDF etc.

OxGarage

Un outil web pour effectuer plusieurs transformations documentaires, par ex

- de DOCX en TEI, et l'inverse
- de HTML en TEI, et l'inverse



I18n

Nous essayons le mieux possible d'internationaliser la TEI!

- Suite à un effort financé par le ALLC (entre autres), les définitions, les gloses, et quelques exemples sont traduits en plusieurs langues, notamment le français, mais aussi:
 - espagnol, portugais, allemand, chinois, koréen, japonais...
- Exception faite de quelques épreuves, les chapitres des Guidelines actuels restent jusqu'à présent en anglais.

L'usage de ODD nous permet de séléctionner une documentation française.



L'idée essentielle de ODD

One Document Does it all

Un vocabulaire spécialisé pour la définition

- des schémas
- des types d'élément XML, indépendant des schémas
- des regroupements de tels éléments, publics ou privés
- des patrons (MLE macros)
- des classes (et sous-classes) d'éléments

Pour la définition des références également, qui permettront de réunir dans un schéma

- des objets identifiables (dans la liste ci-dessus)
- des objets appartenant à d'autres espaces de nom

et qui serait intégrable à un système de balisage documentaire classique



Etre conforme à la TEI veut dire quoi?

- être honnet : Les éléments XML qui se déclarent comme appartenant au namespace TEI doivent respecter les définitions TEI de ces elements
- être explicite: Pour valider un document TEI, un ODD est fortement conseillé, parce que cela mettra en évidence toutes les modifications effectuées
- Tout document valide TEI est valide par rapport au schéma TEI-ALL

L'objet de ces règles est de faciliter le "blind interchange" des documents.



http://www.tei-c.org/Roma/

On va experimenter cela...

TEI	Roma:	generating	validators	for the	TEI
1 61	ixoilia.	generating	valluators	וטו נוופ	

These pages will help you design your own TEI validator, as a DTD, RELAXNG or W3C Schema.				
Create a new or upload existing customization				
Build schema (Create a new customisation by adding elements and modules to the smallest recommended schema)				
Reduce schema (Create a new customization by removing elements and modules from the largest possible schema)				
Create customization from template TEI Absolutely Bare				
Open existing customization Browse				
Start				
Roma was written by Arno Mittelibach and is maintained by Sebastian Rahtz. Sanity check written by Ioan Bernevig. Please direct queries to the TEL® Oxford project.				

- Build up : ajouter ce qu'il vous faut à un schéma minimale
- Reduce: prenez tout ce qui existe et enlever ce qui ne vous interesse pas
- Utilisez un template ou un schema prédéfini
- Retravailler une personalisation déjà faite

